

**Questão 01**

---

Estude os slides sobre Árvore de decisão que estão no CANVAS.

Parte 1 - Algoritmos de Indução de Árvore - Introdução a AD.pdf

Parte 2 - Algoritmos de Indução de Árvore - Como gerar - entendimento geral.pdf Parte 3 - Algoritmos de Indução de Árvore - Como gerar - como calcular.pdf

Parte 4 - Algoritmos de Indução de Árvore - Vantagens e desvantagens.pdf

Parte 5 - Algoritmos de Indução de Árvore - métricas de avaliação.pdf

E responda as seguintes questões:

1) Como uma árvore de decisão é gerada? Qual o significado do atributo que está na raiz da árvore?

**R:** Uma árvore de decisão é gerada a partir deste processo:

1. Definir a regra/objetivo que deseja prever.
2. Definir os atributos que vão ser usados.
3. Escolher o atributo mais informativo (aquele com maior ganho de informação) para ficar na raiz da árvore.
4. Dividir os dados em subconjuntos de acordo com os valores desse atributo.
5. Repetir o processo até chegar em folhas puras (homogêneas).

O atributo que está na raiz é o que traz mais informação, ou seja, o que melhor separa e organiza os dados logo no início.

2) O que você pode fazer com uma árvore de decisão gerada a partir de uma base de dados?

**R:** Com uma árvore de decisão gerada a partir de uma base de dados, é possível classificar exemplos (árvore de classificação) ou prever valores numéricos (árvore de regressão). Ela funciona como uma sequência de perguntas lógicas (ANDs) que dividem os dados em subconjuntos cada vez mais homogêneos até chegar a uma decisão final. Exemplo: dada a pergunta “essa pessoa vai entrar na loja?”, a árvore pode usar atributos como idade, renda ou clima para classificar se a pessoa é um cliente em potencial ou não.

3) Quais as vantagens e desvantagens de um algoritmo de árvore de decisão?

**R: Vantagens:**

- **Flexibilidade:** método não-paramétrico, não assume distribuição dos dados.
- **Seleção de atributos automática:** descarta atributos irrelevantes ou redundantes.
- **Interpretabilidade:** decisões complexas são explicadas por regras simples em sequência.
- **Eficiência:** algoritmo guloso, top-down, com tempo aproximadamente linear no número de exemplos.

**Desvantagens:**

- **Valores ausentes:** exigem mecanismos extras para tratamento.
- **Atributos contínuos:** precisam de ordenação, que pode consumir até 70% do tempo em bases grandes.
- **Instabilidade:** pequenas variações nos dados de treino podem gerar árvores muito diferentes.
- **Confiabilidade das folhas:** decisões próximas da raiz tendem a ser mais confiáveis que as próximas das folhas.

4) Como avaliamos a qualidade de uma árvore?

**R:** Avaliamos a qualidade de uma árvore de decisão pela matriz de confusão, comparando rótulos reais com as previsões. A partir dela, calculamos métricas derivadas como precisão, sensibilidade (recall), acurácia e F1-score, que medem diferentes aspectos do desempenho do modelo

5) Como podemos obter as regras a partir de uma árvore de decisão?

**R:** Podemos obter regras a partir de uma árvore de decisão percorrendo cada caminho da raiz até uma folha. Cada caminho forma uma conjunção de condições (E), e a árvore completa é uma disjunção de conjunções (OU de vários E's). Assim, cada regra é: *“Se (condições sobre atributos) então (classe/decisão final)”*.

Exemplo:

- Se (Cliente = Alguns E Reserva = Sim) → Então = Espera.
- Se (Cliente = Nenhum E Fome = Não) → Então = Não espera.

## Questão 02

---

Considerando-se a base de dados sobre “Esperar ou não pelo restaurante” (verificar base de dados ‘Restaurante.csv’ disponibilizada no CANVAS), pede-se:

1) Calcular o ganho de informação de cada atributo. Que atributo é a raiz da árvore?

Alternativo = 0; Bar = 0; SexSab = 0,021; Fome = 0,196; Cliente = 0,541;

Preço = 0,196; Chuva = 0,021; Res = 0,021; Tipo = 0; Tempo = 0,208;

O atributo raiz da árvore é **Cliente**.

### Alternativo:

Dados:

Não = 6 = (6/12) = conclusão(3 Sim(3/6); 3 Não(3/6))

Sim = 6 = (6/12) = conclusão(3 Sim(3/6); 3 Não(3/6))

Entropia:

Não =  $H(1/2; 1/2) = - (1/2 * \log_2(1/2) + 1/2 * \log_2(1/2)) = 1$

Sim =  $H(1/2; 1/2) = - (1/2 * \log_2(1/2) + 1/2 * \log_2(1/2)) = 1$

Ganho:

$G = 1 - [ 1/2 * 1 + 1/2 * 1 ] = 0$

Ganho de Informação: 0

### Bar:

Dados:

Não = 6 = (6/12) = conclusão(3 Sim(3/6); 3 Não(3/6))

Sim = 6 = (6/12) = conclusão(3 Sim(3/6); 3 Não(3/6))

Entropia:

Não =  $H(1/2; 1/2) = - (1/2 * \log_2(1/2) + 1/2 * \log_2(1/2)) = 1$

Sim =  $H(1/2; 1/2) = - (1/2 * \log_2(1/2) + 1/2 * \log_2(1/2)) = 1$

Ganho:

$G = 1 - [ 1/2 * 1 + 1/2 * 1 ] = 0$

Ganho de Informação: 0

### SexSab:

Dados:

Não = 7 = (7/12) = conclusão(4 Sim(4/7); 3 Não(3/7))

Sim = 5 = (5/12) = conclusão(2 Sim(2/5); 3 Não(3/5))

Entropia:

Não =  $H(4/7; 3/7) = - (4/7 * \log_2(4/7) + 3/7 * \log_2(3/7)) = 0,985$

Sim =  $H(2/5; 3/5) = - (2/5 * \log_2(2/5) + 3/5 * \log_2(3/5)) = 0,971$

Ganho:

$G = 1 - [ 7/12 * 0,985 + 5/12 * 0,971 ] = 0,021$

Ganho de Informação: 0,021

### fome:

Dados:

Não = 5 = (5/12) = conclusão(1 Sim(1/5); 4 Não(4/5))  
 Sim = 7 = (7/12) = conclusão(5 Sim(5/7); 2 Não(2/7))  
 Entropia:  
 $\text{Não} = H(1/5; 4/5) = - (1/5 * \log_2(1/5) + 4/5 * \log_2(4/5)) = 0,722$   
 $\text{Sim} = H(5/7; 2/7) = - (5/7 * \log_2(5/7) + 2/7 * \log_2(2/7)) = 0,863$   
 Ganho:  
 $G = 1 - [ 5/12 * 0,722 + 7/12 * 0,863 ] = 0,196$   
 Ganho de Informação: 0,196

#### **Cliente:**

Dados:  
 Nenhum = 2 = (2/12) = conclusão(0 Sim(0/2); 2 Não(2/2))  
 Alguns = 4 = (4/12) = conclusão(4 Sim(4/4); 0 Não(0/4))  
 Cheio = 6 = (6/12) = conclusão(2 Sim(2/6); 4 Não(4/6))  
 Entropia:  
 $\text{Nenhum} = H(0;1) = 0$   
 $\text{Alguns} = H(1;0) = 0$   
 $\text{Cheio} = H(2/6; 4/6) = - (2/6 * \log_2(2/6) + 4/6 * \log_2(4/6)) = 0,918$   
 Ganho:  
 $G = 1 - [ 2/12 * 0 + 4/12 * 0 + 6/12 * 0,918 ] = 0,541$   
 Ganho de Informação: 0,541

#### **Preco:**

Dados:  
 R = 4 = (4/12) = conclusão(2 Sim(2/4); 2 Não(2/4))  
 RR = 4 = (4/12) = conclusão(2 Sim(2/4); 2 Não(2/4))  
 RRR = 4 = (4/12) = conclusão(2 Sim(2/4); 2 Não(2/4))  
 Entropia:  
 $R = H(2/4; 2/4) = 1$   
 $RR = H(2/4; 2/4) = 1$   
 $RRR = H(2/4; 2/4) = 1$   
 Ganho:  
 $G = 1 - [ 4/12 * 1 + 4/12 * 1 + 4/12 * 1 ] = 0,196$   
 Ganho de Informação: 0,196

#### **Chuva:**

Dados:  
 Não = 8 = (8/12) = conclusão(4 Sim(4/8); 4 Não(4/8))  
 Sim = 4 = (4/12) = conclusão(2 Sim(2/4); 2 Não(2/4))  
 Entropia:  
 $\text{Não} = H(4/8; 4/8) = 1$   
 $\text{Sim} = H(2/4; 2/4) = 1$   
 Ganho:  
 $G = 1 - [ 8/12 * 1 + 4/12 * 1 ] = 0,021$   
 Ganho de Informação: 0,021

#### **Res:**

Dados:  
 Não = 6 = (6/12) = conclusão(3 Sim(3/6); 3 Não(3/6))

Sim = 6 = (6/12) = conclusão(3 Sim(3/6); 3 Não(3/6))

Entropia:

Não =  $H(3/6; 3/6) = 1$

Sim =  $H(3/6; 3/6) = 1$

Ganho:

$G = 1 - [ 6/12 * 1 + 6/12 * 1 ] = 0,021$

Ganho de Informação: 0,021

### **Tipo:**

Dados:

Frances = 2 = (2/12) = conclusão(1 Sim(1/2); 1 Não(1/2))

Tailandes = 2 = (2/12) = conclusão(1 Sim(1/2); 1 Não(1/2))

Hamburger = 2 = (2/12) = conclusão(1 Sim(1/2); 1 Não(1/2))

Italiano = 2 = (2/12) = conclusão(1 Sim(1/2); 1 Não(1/2))

Japones = 2 = (2/12) = conclusão(1 Sim(1/2); 1 Não(1/2))

Steak = 2 = (2/12) = conclusão(1 Sim(1/2); 1 Não(1/2))

Entropia:

Frances =  $H(1/2; 1/2) = 1$

Tailandes =  $H(1/2; 1/2) = 1$

Hamburger =  $H(1/2; 1/2) = 1$

Italiano =  $H(1/2; 1/2) = 1$

Japones =  $H(1/2; 1/2) = 1$

Steak =  $H(1/2; 1/2) = 1$

Ganho:

$G = 1 - [ 2/12 * 1 + 2/12 * 1 + 2/12 * 1 + 2/12 * 1 + 2/12 * 1 + 2/12 * 1 ] = 0$

Ganho de Informação: 0

### **Tempo:**

Dados:

0–10 = 4 = (4/12) = conclusão(4 Sim(4/4); 0 Não(0/4))

10–30 = 2 = (2/12) = conclusão(2 Sim(2/2); 0 Não(0/2))

30–60 = 4 = (4/12) = conclusão(0 Sim(0/4); 4 Não(4/4))

60 = 2 = (2/12) = conclusão(0 Sim(0/2); 2 Não(2/2))

Entropia:

0–10 =  $H(1; 0) = 0$

10–30 =  $H(1; 0) = 0$

30–60 =  $H(0; 1) = 0$

60 =  $H(0; 1) = 0$

Ganho:

$G = 1 - [ 4/12 * 0 + 2/12 * 0 + 4/12 * 0 + 2/12 * 0 ] = 0,208$

Ganho de Informação: 0,208

2) Que atributo estará no segundo nível da árvore? Faça os cálculos e apresente a árvore gerada até o segundo nível da árvore.

**R:** O segundo nível da árvore é tempo.

