

AVALIAÇÃO DE QUALIDADE DOS AGRUPAMENTOS

Cristiane Neri Nobre

Métricas de avaliação

The validation of clustering structures is the most difficult and frustrating part of cluster analysis.

Without a strong effort in this direction, cluster analysis will remain a black art accessible only to those true believers who have experience and great courage."

- Jain and Dubes, Algorithms for Clustering Data, 1988

Validação de agrupamento

Validação é um termo que se refere de forma ampla aos diferentes procedimentos para avaliar de maneira objetiva e quantitativa os resultados de análise de agrupamento

A maneira quantitativa com que se dá um procedimento de validação é alcançada através de algum tipo de **índice**

- **Índice ou Critério de Validade** (de agrupamento)

Validação de agrupamento

Tais índices / critérios podem ser de dois tipos:

Externos: Avalia o grau de correspondência entre a estrutura de grupos (partição ou hierarquia) sob avaliação e informação a priori na forma de uma solução de agrupamento esperada ou conhecida

Internos: Avalia o grau de compatibilidade entre a estrutura de grupos sob avaliação e os dados, usando apenas os próprios dados

Critérios de validade externos

Embora o problema de clustering seja não supervisionado, em alguns cenários o resultado de agrupamento desejado pode ser conhecido.

- Base de dados da Iris

Índices que medem o nível de compatibilidade entre uma partição obtida e uma partição de referência dos mesmos dados são denominados **critérios de validade externos**

Cr terios de validade externos

Existem v rios cr terios externos na literatura:

- Rand Index
- Jaccard
- Rand Index Ajustado
- Estat stica
- Overall F-Measure
- Normalized Mutual Information

Critérios de validade internos

De maneira geral, em análise de agrupamento prática, normalmente não se dispõe de uma partição ou hierarquia de referência para validar a estrutura de grupos obtida

- Ou seja, temos apenas os dados e o resultado a ser avaliado

Critérios que avaliam a estrutura de grupos obtida utilizando apenas os próprios dados são denominados **critérios internos de validade** de agrupamento

Cr terios de validade internos

- Coeficiente de Silhouette
- Sum of Squared Error (SSE)
- Davies-Bouldin
- Dunn
- Calinski-Harabasz


Métricas de avaliação

Silhouette Index

O Silhouette Index é uma medida de avaliação que avalia a coesão e a separação dos clusters, e baseia-se na diferença entre a distância média dos pontos pertencentes ao cluster mais próximo para os pontos de um grupo.

Métricas de avaliação - Silhouette Index

Para cada ponto da base de dados, x_i , é calculado o valor do silhouette index, S_i , de acordo com a Equação:



$$S_i = \frac{\mu_{out}^{min}(x_i) - \mu_{in}(x_i)}{\max\{\mu_{out}^{min}(x_i), \mu_{in}(x_i)\}}$$

Onde:


$\mu_{in}(x_i)$ é a distância média de x_i para os **pontos do seu próprio cluster**, e

$\mu_{out}^{min}(x_i)$ é a distância média de x_i para os **pontos dos clusters mais próximo**.

Métricas de avaliação

Onde:


- $\mu_{in}(x_i)$ é a distância média de x_i para os pontos do seu próprio cluster, e



Métricas de avaliação


Onde:

- $\mu_{out}^{min}(x_i)$ é a distância média de x_i para os pontos dos clusters mais próximo.
- Como saber qual o cluster mais próximo?



Métricas de avaliação

Assim, faz-se esta conta para cada instância da base de dados



$$S_i = \frac{\mu_{out}^{min}(x_i) - \mu_{in}(x_i)}{\max\{\mu_{out}^{min}(x_i), \mu_{in}(x_i)\}}$$

Métricas de avaliação

Silhouette Index

- O valor S_i de um ponto encontra-se no intervalo $[-1, 1]$.
- Um valor próximo a 1 indica que x_i está mais próximo dos pontos do seu **próprio cluster** e distante dos clusters vizinhos.
- Um valor próximo de 0 indica que x_i está próximo da **fronteira de dois clusters**.
- Finalmente, um valor próximo a -1 indica que x_i está **próximo dos pontos que pertencem a outro cluster**.

Métricas de avaliação

Silhouette Index

- O valor S_i de um ponto encontra-se no intervalo $[-1, 1]$.
- Um valor próximo a 1 indica que x_i está mais próximo dos pontos do seu **próprio cluster** e distante dos clusters vizinhos.
- Um valor próximo de 0 indica que x_i está próximo da **fronteira de dois clusters**.
- Finalmente, um valor próximo a -1 indica que x_i está **próximo dos pontos que pertencem a outro cluster**

Métricas de avaliação

Silhouette Index

O silhouette index é definido como o valor médio S_i entre todos os pontos, dado pela Equação

$$SilhouetteIndex = \frac{1}{n} \sum_{i=e}^n S_i$$

Métricas de avaliação

Silhouette Index

Segundo Rousseeuw (1987), para cada grupo é apresentado um valor do silhouette index, baseado na comparação da sua coesão (análise intra-cluster) e separação (com os demais grupos).

Este índice mostra quais objetos se encontram adequadamente agrupados no cluster e quais estão localizados indevidamente no cluster.

Todo o agrupamento é exibido pela combinação dos silhouettes em um único valor, permitindo uma validação da qualidade relativa dos clusters e uma visão geral da distribuição dos dados.

A largura média do silhouette index fornece uma avaliação da validade de agrupamento e pode ser utilizada para selecionar um número apropriado de aglomerados.

Métricas de avaliação

Silhouette Index

Os valores do silhouette index são avaliados levando em consideração a Tabela seguinte.

Tabela 1 – Análise do *Silhouette Index*

Valor	Significado
0.71 - 1.0	Uma estrutura forte foi encontrada
0.51 - 0.70	Uma estrutura razoável foi encontrada
0.26 - 0.50	A estrutura é fraca e pode ser artificial
< 0.25	Nenhuma estrutura substancial foi encontrada

Fonte: Adaptado de Rousseeuw (1987)

Métricas de avaliação

Sum of Squared Error (SSE)

- Para cada ponto, o erro é a distância ao grupo mais próximo
- Para obter SSE, os erros são elevados ao quadrados e somados

$$SSE = \sum_{i=1}^k \sum_{p \in C_i} dist(p, c_i)^2$$

onde p é um objeto dentro do cluster C_i , c_i é o centroide do cluster C_i e $dist(p, c_i)$ é a distância euclidiana entre um objeto p e o centroide c_i .

Métricas de avaliação

Sum of Squared Error (SSE)

- Uma forma fácil de reduzir SSE é aumentar o número de grupos, k
- Um bom agrupamento com k menor pode ter um SSE inferior que um agrupamento pobre com k maior

Métricas de avaliação

Investigue outras métricas!

Ex: Davies-Bouldin Index

Veja:

<https://www.youtube.com/watch?v=438C3vGxYTE>

Referências

<https://www.youtube.com/watch?v=438C3vGxYTE>

<https://medium.com/@gilneyjnr/qualidade-de-agrupamentos-ci%C3%A2ncia-de-dados-4b1176bef5e5>

http://each.uspnet.usp.br/sarajane/wp-content/uploads/2015/11/avaliacao_clustering.pdf

http://www.dca.fee.unicamp.br/~lboccato/topico_8_clusterizacao.pdf

Livro:

Jain and Dubes, Algorithms for Clustering Data, 1988

Neste vídeo, aprendemos:

Sobre como avaliar a qualidade dos algoritmos de agrupamento?

No próximo vídeo, veremos **algumas considerações sobre o K-means e algoritmos de agrupamento**