



PUC Minas

Arquitetura de Computadores III

Clusters, WSC e MP com Passagem de Mensagens

- Arquiteturas paralelas podem utilizar **memória compartilhada** ou **passagem explícita de mensagens**.
- Em sistemas de passagem de mensagens, cada processador possui seu próprio espaço de endereçamento físico.
- A comunicação ocorre por envio e recebimento explícito de mensagens.
- Essa abordagem é amplamente utilizada em clusters, datacenters e computação em nuvem.
- Comunicação explícita substitui a memória compartilhada como mecanismo de cooperação entre processos.

Clusters, WSC e MP com Passagem de Mensagens

Memória Compartilhada vs. Espaços de Endereçamento Privados

- Multiprocessadores podem ser organizados com um único espaço de memória compartilhado.
- Alternativamente, cada nó pode possuir memória privada independente.
- Quando não existe memória compartilhada, toda comunicação deve ocorrer por mensagens.
- Essa organização elimina a necessidade de coerência de cache entre os nós.
- Em sistemas de passagem de mensagens, dados não são compartilhados automaticamente.

Clusters, WSC e MP com Passagem de Mensagens

Organização de um Sistema de Passagem de Mensagens

- Cada processador possui:
 - CPU própria;
 - memória local própria;
 - sistema operacional próprio.
- Os nós são conectados por uma rede de comunicação.
- Não existe acesso direto à memória de outro nó.
- Toda transferência de dados passa pela rede.

Clusters, WSC e MP com Passagem de Mensagens

Comunicação por Passagem de Mensagens

Processo básico

1. Um nó envia uma mensagem.
2. A rede transporta a mensagem.
3. O nó destino recebe a mensagem.
4. Opcionalmente, envia uma confirmação (acknowledgment).
 - O envio e recebimento são eventos explícitos para o software.
 - A sincronização ocorre naturalmente através das mensagens.
 - O programador controla exatamente quando ocorre a comunicação.

Clusters, WSC e MP com Passagem de Mensagens

Redes de Alto Desempenho para Passagem de Mensagens

- Diversos supercomputadores utilizam redes especializadas de baixa latência.
- Essas redes oferecem desempenho superior ao Ethernet convencional.
- O custo da infraestrutura costuma ser significativamente maior.
- Aplicações científicas e HPC frequentemente justificam esse investimento.
- Fora do HPC, o benefício raramente compensa o aumento de custo.

Clusters, WSC e MP com Passagem de Mensagens

Vantagens para o Hardware

- Não há necessidade de protocolos complexos de coerência de cache.
- Menor complexidade de projeto.
- Escalabilidade mais simples.
- Menor tráfego associado à manutenção da consistência de memória.
- Sistemas de Passagem de Mensagens são mais fáceis de construir do ponto de vista arquitetural.

Clusters, WSC e MP com Passagem de Mensagens

Vantagens para o Programador

- Comunicação é explícita.
- Menos comportamentos inesperados de desempenho.
- O programador sabe exatamente onde ocorrem transferências de dados.
- Facilita análise de gargalos de comunicação.
- Comunicação explícita gera maior previsibilidade de desempenho.

Clusters, WSC e MP com Passagem de Mensagens

Desvantagens para o Programador

- Todo fluxo de dados deve ser planejado antecipadamente.
- Comunicações esquecidas causam falhas de funcionamento.
- Portar programas sequenciais torna-se mais difícil.
- O programador assume responsabilidades que, em memória compartilhada, são tratadas pelo hardware.
- Simplicidade de hardware implica maior responsabilidade do software.

Clusters, WSC e MP com Passagem de Mensagens

Onde Sistemas de Passagem de Mensagens Funciona Bem?

- Aplicações com pouca comunicação.
- Paralelismo em nível de tarefas (Task-Level Parallelism).
- Serviços independentes executados simultaneamente.
- Exemplos:
 - motores de busca;
 - servidores de e-mail;
 - servidores de arquivos.
- Nesses casos, a ausência de memória compartilhada raramente é um problema.

Clusters, WSC e MP com Passagem de Mensagens

Clusters: O Principal Exemplo Atual

- Cluster = conjunto de computadores independentes conectados por rede.
- Cada nó executa uma cópia independente do sistema operacional.
- Comunicação realizada por passagem de mensagens.
- Atualmente representam a forma mais difundida de computação paralela em larga escala.
- Um cluster é composto por computadores completos cooperando através de rede.

Clusters, WSC e MP com Passagem de Mensagens

Comparação com Multiprocessadores Compartilhados

Característica	Cluster	Memória Compartilhada
SO	Um por nó	Um único SO
Comunicação	Mensagens	Memória
Latência	Maior	Menor
Largura de banda	Menor	Maior
Escalabilidade	Alta	Limitada

- Interconexões de memória são mais rápidas que redes convencionais.
- Multiprocessadores compartilhados oferecem melhor desempenho de comunicação.

Clusters, WSC e MP com Passagem de Mensagens

Dependabilidade como Vantagem dos Clusters

- Falhas podem ser isoladas em um único servidor.
- Substituição de máquinas é relativamente simples.
- Não é necessário desligar todo o sistema.
- O cluster pode continuar operando com capacidade reduzida.
- A separação física dos nós aumenta a disponibilidade do sistema.

Clusters, WSC e MP com Passagem de Mensagens

Escalabilidade Incremental

- Novos servidores podem ser adicionados gradualmente.
- Expansão ocorre sem interromper aplicações.
- Rede e servidores são componentes independentes.
- Crescimento pode acompanhar a demanda do serviço.
- Clusters favorecem crescimento contínuo e modular.

Clusters, WSC e MP com Passagem de Mensagens

Clusters na Indústria

- Menor custo que multiprocessadores compartilhados de grande porte.
- Alta disponibilidade.
- Fácil expansão.
- Base da infraestrutura moderna da Internet.
- Exemplos:
 - Amazon
 - Google
 - Microsoft
 - Meta/Facebook
- Cada uma opera múltiplos datacenters com dezenas de milhares de servidores.

Clusters, WSC e MP com Passagem de Mensagens

Surgimento dos Warehouse-Scale Computers (WSC)

- Crescimento dos serviços de Internet exigiu instalações gigantescas.
- Datacenters passaram a concentrar dezenas de milhares de servidores.
- Infraestrutura inclui:
 - energia elétrica;
 - refrigeração;
 - redes;
 - monitoramento.
- Surge uma nova categoria computacional: Warehouse-Scale Computer (WSC).

Clusters, WSC e MP com Passagem de Mensagens

O que é um Warehouse-Scale Computer?

- Aproximadamente 50.000 servidores ou mais.
- Opera como um único computador lógico.
- Custo total pode alcançar centenas de milhões de dólares.
- Arquitetura e operação muito mais sofisticadas que clusters convencionais.
- Um WSC é um computador cujo tamanho é um prédio inteiro.

Clusters, WSC e MP com Passagem de Mensagens

Frameworks para Processamento em WSC

MapReduce e Hadoop

- Modelo dominante para processamento em lote.
- Desenvolvido inicialmente pelo Google.
- Hadoop é a implementação open-source mais conhecida.
- Explora paralelismo massivo em milhares de servidores.

Clusters, WSC e MP com Passagem de Mensagens

Modelo MapReduce

- **Etapas**
 1. Dados de entrada são divididos.
 2. Funções Map processam subconjuntos.
 3. Resultados intermediários são agrupados por chave.
 4. Funções Reduce agregam os resultados finais.
- MapReduce transforma grandes problemas em milhares de tarefas independentes

Clusters, WSC e MP com Passagem de Mensagens

Exemplo: Contagem de Palavras

- Problema:
 - Determinar quantas vezes cada palavra aparece em uma coleção de documentos.
- Map:
 - Emite (palavra,1) para cada ocorrência.
- Reduce:
 - Soma todos os valores associados à mesma palavra.
- Resultado:
 - (palavra,total_de_ocorrências)

Clusters, WSC e MP com Passagem de Mensagens

Código exemplo de MapReduce

map(String key, String value):

// key: document name

// value: document contents

for each word w **in** value:

EmitIntermediate(w, "1"); // Produce list of all words

reduce(String key, Iterator values):

// key: a word

// values: a list of counts

int result = 0;

for each v **in** values:

result += ParseInt(v); // get integer from key-value pair

Emit(AsString(result));

Clusters, WSC e MP com Passagem de Mensagens

Por que MapReduce é Popular?

- Modelo simples.
- Altamente escalável.
- Oculta detalhes de distribuição.
- Tolerante a falhas.
- Permite que programadores iniciantes utilizem milhares de servidores.

Clusters, WSC e MP com Passagem de Mensagens

WSCs: Herdeiros dos Supercomputadores

- Assim como os supercomputadores de Seymour Cray:
 - resolvem problemas impossíveis em máquinas menores;
 - exigem infraestrutura especializada.
- Diferença principal:
 - foco atual é serviços globais de informação.
 - não apenas computação científica.

Clusters, WSC e MP com Passagem de Mensagens

Característica 1: Request-Level Parallelism (RLP)

- Milhões de requisições independentes.
- Pouca necessidade de sincronização.
- Usuários normalmente não dependem uns dos outros.
- Exemplos:
 - Busca na Web.
 - E-mail.
 - Redes sociais.
 - Comércio eletrônico.
- O paralelismo surge naturalmente das requisições independentes.

Clusters, WSC e MP com Passagem de Mensagens

Característica 2: Custos Operacionais

- Vida útil de 10 a 20 anos.
- Energia elétrica torna-se fator crítico.
- Custos de refrigeração são significativos.
- Energia, distribuição elétrica e refrigeração representam mais de 30% do custo total.
- Eficiência energética é um requisito arquitetural.

Clusters, WSC e MP com Passagem de Mensagens

Característica 3: Escala Massiva

- Compra de dezenas de milhares de servidores.
- Ganhos de economia de escala.
- Menor custo por servidor.
- Viabilização econômica da computação em nuvem.
- O tamanho reduz o custo unitário dos recursos computacionais.

Clusters, WSC e MP com Passagem de Mensagens

O Problema das Falhas em Grande Escala

- **Exemplo**
 - MTTF de servidor = 25 anos.
 - WSC com 50.000 servidores.
- **Resultado:**
 - Aproximadamente 5 falhas de servidores por dia.
- **Consequência:**
 - Falhas deixam de ser exceções.
 - Devem ser consideradas normais no projeto.

Clusters, WSC e MP com Passagem de Mensagens

Falhas de Disco em WSC

- **Exemplo**
 - 50.000 servidores.
 - 4 discos por servidor.
 - AFR = 4%.
- **Resultado:**
 - ?

Clusters, WSC e MP com Passagem de Mensagens

Falhas de Disco em WSC

- **Exemplo**
 - 50.000 servidores.
 - 4 discos por servidor.
 - AFR = 4%.
- **Resultado:**
 - $4 \times 50000 \times 0,04 / (365 \times 24) \approx 1$ (Aproximadamente uma falha de disco por hora)
- Tolerância a falhas é requisito fundamental em WSCs.

Clusters, WSC e MP com Passagem de Mensagens

WSCs e Computação em Nuvem

- Economias de escala permitiram oferecer infraestrutura como serviço.
- Usuários alugam recursos sob demanda.
- Elimina necessidade de grandes investimentos iniciais.
- Computação torna-se um serviço utilitário.
- Cloud computing é consequência direta dos WSCs.

Clusters, WSC e MP com Passagem de Mensagens

Crescimento da Computação em Nuvem

- AWS adiciona capacidade diariamente em escala gigantesca.
- Cloud tornou-se uma das áreas mais lucrativas da indústria.
- Crescimento impulsionado por:
 - elasticidade;
 - baixo custo inicial;
 - disponibilidade global.

Clusters, WSC e MP com Passagem de Mensagens

Síntese

- Sistemas de Passagem de Mensagens utiliza memórias privadas e comunicação explícita.
- Clusters são a implementação dominante dessa abordagem.
- WSCs representam a evolução dos clusters para escala planetária.
- MapReduce viabilizou processamento massivo de dados.
- Escala traz economia, mas exige tolerância permanente a falhas.
- Computação em nuvem é resultado direto dessa evolução.

Clusters, WSC e MP com Passagem de Mensagens

Interconexão de Nós em Sistemas Paralelos

- Como conectar milhares de servidores?
- Topologias de rede para clusters e WSCs.
- Redes em chips multicore (Network-on-Chip).
- Impacto da latência e largura de banda no desempenho.
- Compreender os multiprocessadores e Sistemas de Passagem de Mensagens exige entender também as redes que conectam seus nós.

Introdução às Topologias de Redes para Multiprocessadores

- Processadores multicore utilizam redes em chip (NoCs) para interligar núcleos.
- Clusters utilizam redes locais para conectar servidores distribuídos.
- A topologia da rede influencia desempenho, custo, escalabilidade e consumo de energia.
- Diferentes aplicações paralelas podem exigir diferentes organizações de interconexão.
- O estudo das topologias busca equilibrar custo de implementação e eficiência de comunicação.
- A rede é um componente crítico em sistemas paralelos modernos.

Introdução às Topologias de Redes para Multiprocessadores

O Papel da Rede em Sistemas Paralelos

- A comunicação entre processadores ocorre por meio de uma rede de interconexão.
- A eficiência da comunicação pode limitar o desempenho global da aplicação paralela.
- Redes são utilizadas tanto dentro de um chip quanto entre servidores de um datacenter.
- O projeto da rede impacta diretamente escalabilidade e throughput do sistema.
- Em muitos sistemas paralelos, o gargalo não está no processador, mas na comunicação.

Introdução às Topologias de Redes para Multiprocessadores

Custos de uma Rede de Interconexão

- Número de switches necessários para formar a rede.
- Quantidade de links conectados a cada switch.
- Largura dos links (número de bits transmitidos simultaneamente).
- Comprimento físico dos links.
- Complexidade da implementação física no chip ou datacenter.
- O custo cresce tanto com a quantidade quanto com a complexidade das conexões.

Introdução às Topologias de Redes para Multiprocessadores

Métricas de Desempenho de Redes

- **Latência:** tempo para transmitir uma mensagem entre origem e destino.
- **Throughput:** quantidade máxima de mensagens transmitidas por unidade de tempo.
- **Contenção:** atrasos causados por múltiplas comunicações competindo pelos mesmos recursos.
- Sensibilidade ao padrão de comunicação da aplicação.
- Tolerância a falhas e eficiência energética também são fatores relevantes.
- Não existe uma única métrica capaz de caracterizar completamente uma rede.

Introdução às Topologias de Redes para Multiprocessadores

Representação de Redes como Grafos

- Redes são normalmente representadas por grafos.
- Vértices representam processadores ou switches.
- Arestas representam links de comunicação.
- Os links podem ser bidirecionais ou não.
- A comunicação pode ocorrer entre nós adjacentes ou através de múltiplos saltos.

Introdução às Topologias de Redes para Multiprocessadores

Componentes de uma Rede

- Nós processador-memória executam programas e armazenam dados.
- Switches realizam o encaminhamento das mensagens.
- Links conectam switches entre si e aos processadores.
- A combinação desses elementos define a topologia da rede.
- O roteamento determina o caminho percorrido pelas mensagens.

Introdução às Topologias de Redes para Multiprocessadores

Topologia em Anel (Ring)

- Cada nó é conectado a dois vizinhos.
- Forma uma estrutura circular fechada.
- Nem todos os nós possuem conexão direta.
- Mensagens podem atravessar diversos nós intermediários.
- A comunicação ocorre por múltiplos saltos (hops).



Introdução às Topologias de Redes para Multiprocessadores

Ring versus Barramento (Bus)

- O barramento utiliza um conjunto compartilhado de fios.
- Apenas uma transmissão efetiva ocorre por vez.
- O anel permite múltiplas transferências simultâneas.
- O barramento favorece broadcast.
- O anel favorece paralelismo de comunicação.

Característica	Bus	Ring
Broadcast	Excelente	Limitado
Paralelismo	Baixo	Alto
Escalabilidade	Limitada	Melhor

Introdução às Topologias de Redes para Multiprocessadores

Métrica: Largura de Banda Total

- Mede a capacidade máxima teórica da rede.
- Calculada como:

$$\textit{Bandwidth Total} = \textit{Bandwidth por Link} \times \textit{Número de Links}$$

- Representa o melhor caso possível.
- Assume utilização ideal da rede.
- Não considera congestionamentos.

Introdução às Topologias de Redes para Multiprocessadores

Largura de Banda Total do Ring

- Considere P processadores.
- Existem aproximadamente P links no anel.
- Logo:

$$BW_{total} = P \times BW_{link}$$

- O desempenho cresce linearmente com o número de nós.
- Múltiplas comunicações simultâneas podem ocorrer.

Introdução às Topologias de Redes para Multiprocessadores

Métrica: Bisection Bandwidth

- Procura medir o pior caso da rede.
- Divide-se a máquina em duas metades.
- Soma-se a largura de banda dos links que cruzam a divisão.
- Mede a capacidade de comunicação entre as duas metades.
- Frequentemente mais relevante que a largura de banda total.

Introdução às Topologias de Redes para Multiprocessadores

Exemplo de Bisection Bandwidth

Passos para cálculo

1. Dividir a rede em duas partes.
2. Identificar os links cortados.
3. Somar suas larguras de banda.
4. Escolher a divisão com menor resultado.

Introdução às Topologias de Redes para Multiprocessadores

Bisection Bandwidth do Ring e do Bus

Para um link de largura B:

- Ring:
 - $BW_{bisection} = 2B$
- Bus:
 - $BW_{bisection} = B$
- No pior caso, o anel é apenas duas vezes melhor.
- No melhor caso, o anel pode ser P vezes superior.

Introdução às Topologias de Redes para Multiprocessadores

Por que Considerar o Pior Caso?

- Algumas topologias não são simétricas.
- O desempenho depende da posição do corte.
- Deve-se analisar todas as divisões possíveis.
- Escolhe-se a menor largura de banda encontrada.
- Programas paralelos frequentemente são limitados pelo ponto mais fraco da comunicação.
- O desempenho global tende a ser determinado pelo gargalo da rede.

Introdução às Topologias de Redes para Multiprocessadores

Topologia Totalmente Conectada

- Cada processador possui ligação direta com todos os demais.
- Não há necessidade de nós intermediários.
- Comunicação ocorre em apenas um salto.
- Minimiza latência.
- Maximiza largura de banda.

Introdução às Topologias de Redes para Multiprocessadores

Métricas da Rede Totalmente Conectada

- Para P processadores:

$$BW_{total} = P(P-1)/2$$

$$BW_{bisec} = (P/2)^2$$

- Crescimento quadrático da capacidade.
- Excelente desempenho.
- Elevado custo de implementação.

Introdução às Topologias de Redes para Multiprocessadores

O Problema da Rede Totalmente Conectada

- Número de links cresce quadraticamente.
- Complexidade física aumenta rapidamente.
- Consumo energético torna-se elevado.
- Escalabilidade prática é limitada.
- Pouco viável para grandes sistemas.
- Máximo desempenho implica custo extremamente elevado.

Introdução às Topologias de Redes para Multiprocessadores

O Compromisso Fundamental

- **Ring:** baixo custo e desempenho moderado.
- **Fully Connected:** alto desempenho e alto custo.
- Projetistas buscam soluções intermediárias.
- A melhor escolha depende da aplicação.
- O padrão de comunicação influencia fortemente o resultado.

Introdução às Topologias de Redes para Multiprocessadores

Topologias Comerciais Populares

- Muitas topologias foram propostas na literatura.
- Apenas algumas chegaram a produtos comerciais.
- Critérios principais:
 - Custo
 - Escalabilidade
 - Desempenho
 - Eficiência energética
- O sucesso depende da carga de trabalho.

Introdução às Topologias de Redes para Multiprocessadores

Redes Multiestágio

- Nem todos os nós precisam conter processadores.
- Alguns vértices possuem apenas switches.
- Switches são menores e mais densos.
- Reduzem distâncias físicas.
- Melhoram potencialmente o desempenho.
- Redes multiestágio separam processamento e roteamento.


Introdução às Topologias de Redes para Multiprocessadores

Rede Crossbar

- Permite conectar qualquer entrada a qualquer saída.
- Comunicação ocorre em uma única passagem.
- Não há bloqueios internos.
- Elevado desempenho.
- Custo cresce quadraticamente.

Introdução às Topologias de Redes para Multiprocessadores

Rede Crossbar



a. Crossbar


Introdução às Topologias de Redes para Multiprocessadores

Rede Omega


- Alternativa mais barata ao Crossbar.
- Utiliza múltiplos estágios de switches.
- Necessita menos hardware.
- Permite comunicação entre quaisquer nós.
- Pode sofrer contenção.

Introdução às Topologias de Redes para Multiprocessadores

Rede Omega



b. Omega network



c. Omega network switch box


Introdução às Topologias de Redes para Multiprocessadores

Custo: Crossbar versus Omega


- Para n entradas:
 - Crossbar: n^2
 - Omega: $2n \log_2 n$
 - switches/conexões.
- Grande redução de hardware.
- Melhor escalabilidade.

Introdução às Topologias de Redes para Multiprocessadores

Outras redes



a. 2D grid or torus of 16 nodes



b. n -cube tree of 8 nodes ($8 = 2^3$ so $n = 3$)

Introdução às Topologias de Redes para Multiprocessadores

Implementação Física das Topologias

- A análise teórica ignora restrições físicas.
- Distância dos links afeta desempenho.
- Links longos possuem maior custo.
- Links longos consomem mais energia.
- Frequências elevadas tornam-se mais difíceis.
- Uma topologia elegante nem sempre é fisicamente viável.

Introdução às Topologias de Redes para Multiprocessadores

Restrições de Implementação em Chips

- Chips são essencialmente bidimensionais.
- Redes tridimensionais precisam ser mapeadas em 2D.
- Roteamento físico pode aumentar complexidade.
- Comprimento dos fios afeta latência.
- Energia tornou-se fator dominante de projeto.

Introdução às Topologias de Redes para Multiprocessadores

Energia e Escolha de Topologias

- O consumo energético limita arquiteturas modernas.
- Topologias simples podem ser preferidas.
- Grades (mesh/grid) tornaram-se populares em NoCs.
- Menos conexões significam menor custo energético.
- O melhor desempenho nem sempre é a melhor escolha.

Introdução às Topologias de Redes para Multiprocessadores

Síntese

- Redes são fundamentais para multicore e clusters.
- Métricas principais:
 - largura de banda total;
 - bisection bandwidth.
- Ring oferece baixo custo.
- Fully Connected oferece máximo desempenho.
- Crossbar e Ômega representam soluções intermediárias.
- Implementação física e energia influenciam fortemente a escolha da topologia.
- O projeto de redes de interconexão é um problema de compromisso entre desempenho, custo, escalabilidade e energia.