

Análise de Regressão



Tópicos

- ▶ Correlação
- ▶ Regressão Linear Simples

Correlação


- ▶ **Correlação:** É uma medida que que está entre -1 e 1 e mede a relação entre duas variáveis.




Karl Pearson
1857-1936


Regressão Linear Simples

Regressão: É uma técnica estatística que visa explorar o relacionamento entre duas ou mais variáveis, podendo ser utilizada na construção de modelos de predição, por meio do ajuste de uma reta de regressão ou equação de regressão.



Sir Francis Galton
1822-1911






População: N

Altura vs. Peso

Questão:


Existe relação entre
as duas variáveis?



Qual modelo me
descreve esta relação?






Corr (x,y)



Amostra: n

Gráficos de dispersão

$$-1 \leq \text{Corr}(x, y) \leq 1$$



Correlação Amostral

$$Sxx = n\sum x^2 - (\sum x)^2$$

$$Syy = n\sum y^2 - (\sum y)^2$$

$$Sxy = n\sum xy - (\sum x)(\sum y)$$

$$Corr(x, y) = \frac{Sxy}{\sqrt{Sxx * Syy}}$$


Problema

Dados o tempo de serviço em anos de 10 funcionários de uma seguradora e a quantidade de clientes que cada um possui, verifique se existe uma associação entre as variáveis.

ID	A	B	C	D	E	F	G	H	I	J
TEMPO DE SERVIÇO	2	3	4	5	4	6	7	8	8	10
QTDE. FUNCIONÁRIOS	48	50	56	52	43	60	62	58	64	72

Gráfico de dispersão

ID	X	Y
A	2	48
B	3	50
C	4	56
D	5	52
E	4	43
F	6	60
G	7	62
H	8	58
I	8	64
J	10	72



Correlação Amostral

ID	X	Y	X ²	Y ²	XY
A	2	48	4	2304	96
B	3	50	9	2500	150
C	4	56	16	3136	224
D	5	52	25	2704	260
E	4	43	16	1849	172
F	6	60	36	3600	360
G	7	62	49	3844	434
H	8	58	64	3364	464
I	8	64	64	4096	512
J	10	72	100	5184	720
Σ	57	565	383	32581	3392

$$S_{xx} = n\sum x^2 - (\sum x)^2 = 10 * 383 - 57^2 = 581$$

$$S_{yy} = n\sum y^2 - (\sum y)^2 = 10 * 32581 - 565^2 = 6585$$


$$S_{xy} = n\sum xy - (\sum x)(\sum y) = 10 * 3392 - 57 * 565 = 1715$$

$$Corr(x, y) = \frac{S_{xy}}{\sqrt{S_{xx} * S_{yy}}} = \frac{1715}{\sqrt{581 * 6585}} = 0,8768$$

Regressão Linear Simples


Modelo Teórico

$$y = \beta_0 + \beta_1 x + \varepsilon$$



y é a variável dependente ou resposta.
 x é a variável independente ou explicativa.

Modelo de Regressão Linear Simples - Ajuste



Estimação : Regressão Linear Simples

► Método de Mínimos Quadrados :

► Minimizar: $S(\beta_0, \beta_1) = \sum (y_i - \beta_0 - \beta_1 x_i)^2$

$$y = \beta_0 + \beta_1 x + \varepsilon$$

$$\hat{\beta}_0 = \bar{y} - \hat{\beta}_1 \bar{x}$$

$$\hat{\beta}_1 = \frac{S_{xy}}{S_{xx}}$$


Problema

Dados o tempo de serviço em anos de 10 funcionários de uma seguradora e a quantidade de clientes que cada um possui, verifique se existe uma associação entre as variáveis.

ID	A	B	C	D	E	F	G	H	I	J
TEMPO DE SERVIÇO	2	3	4	5	4	6	7	8	8	10
QTDE. FUNCIONÁRIOS	48	50	56	52	43	60	62	58	64	72

Equação da Reta de Regressão

ID	X	Y
A	2	48
B	3	50
C	4	56
D	5	52
E	4	43
F	6	60
G	7	62
H	8	58
I	8	64
J	10	72



Estimação dos Parâmetros

ID	X	Y	X ²	Y ²	XY
A	2	48	4	2304	96
B	3	50	9	2500	150
C	4	56	16	3136	224
D	5	52	25	2704	260
E	4	43	16	1849	172
F	6	60	36	3600	360
G	7	62	49	3844	434
H	8	58	64	3364	464
I	8	64	64	4096	512
J	10	72	100	5184	720
Σ	57	565	383	32581	3392

$$S_{xx} = n\sum x^2 - (\sum x)^2 = 10 * 383 - 57^2 = 581$$

$$S_{yy} = n\sum y^2 - (\sum y)^2 = 10 * 32581 - 565^2 = 6585$$

$$S_{xy} = n\sum xy - (\sum x)(\sum y) = 10 * 3392 - 57 * 565 = 1715$$


$$\hat{\beta}_0 = \bar{y} - \hat{\beta}_1 \bar{x}$$

$$\hat{\beta}_1 = \frac{S_{xy}}{S_{xx}} = \frac{1715}{581} = 2,9518$$

$$\hat{\beta}_0 = 56,5 - 2,9518 * 5,7 = 39,6747$$

Modelo de Regressão - Ajuste

$$y = 39,67 + 2,95x + \varepsilon$$



Modelo de Predição


- Assumindo que o modelo de regressão ajustado é adequado, qual a previsão da quantidade de clientes para um funcionário com 8 anos de empresa?

$$y = 39,67 + 2,95 * 8 = 63,286 \cong 63 \text{ clientes}$$

Qualidade de ajuste do modelo de regressão

Partições da variabilidade

$$\sum (y - \bar{y})^2 = \sum (\hat{y} - \bar{y})^2 + \sum (y - \hat{y})^2$$



$$SS_T = SS_R + SS_E$$

Partições da variabilidade

ID	x	y	$\hat{y}$	$(y - \hat{y})^2$	$(\hat{y} - \bar{y})^2$	$(y - \bar{y})^2$
A	2	48	45,58	5,86	119,25	72,25
B	3	50	48,53	2,16	63,52	42,25
C	4	56	51,48	20,41	25,20	0,25
D	5	52	54,43	5,92	4,28	20,25
E	4	43	51,48	71,94	25,20	182,25
F	6	60	57,39	6,84	0,79	12,25
G	7	62	60,34	2,76	14,75	30,25
H	8	58	63,29	27,98	46,10	2,25
I	8	64	63,29	0,51	46,10	56,25
J	10	72	69,19	7,88	161,04	240,25
soma	57	565	565	152,26	506,24	658,50

O coeficiente de determinação R²

- ▶ O coeficiente de determinação, R², é a razão entre a variação explicada em $\hat{y}$ (SQR) e a variação total em y (SQT).
- ▶ O coeficiente de determinação é dado por:

$$R^2 = \frac{SQR}{SQT}$$

- ▶ Assim:

$$R^2 = \frac{506,24}{608,50} = 0,7688 \text{ ou } 76,88\%$$

O coeficiente de determinação R^2

- ▶ Outra forma de encontrar o coeficiente de determinação é utilizando o coeficiente de correlação: $R^2 = (\text{corr}(x,y))^2$
- ▶ O coeficiente de correlação entre anos de empresa e quantidade de clientes é de : $\text{corr}(x,y) = 0,8768$.
- ▶ Assim o coeficiente de determinação é $R^2 = (\text{corr}(x,y))^2 = (0,8768)^2 = 0,7688$ ou 76,88%.
- ▶ Interpretação: Temos que 76,88% da variação do número de clientes pode ser explicada pelo anos de empresa do funcionário. Os outros 23,12% não são explicados e podem ser atribuídos ao erro aleatório amostral ou outras variáveis não observadas no estudo.

O erro padrão da estimativa

- ▶ O erro padrão da estimativa, s_e , é o desvio padrão dos valores y_i observados em torno do valor $\hat{y}$ previsto.

ID	x	y	$\hat{y}$	$(y - \hat{y})$	$(y - \hat{y})^2$
A	2	48	45,58	2,42	5,86
B	3	50	48,53	1,47	2,16
C	4	56	51,48	4,52	20,41
D	5	52	54,43	-2,43	5,92
E	4	43	51,48	-8,48	71,94
F	6	60	57,39	2,61	6,84
G	7	62	60,34	1,66	2,76
H	8	58	63,29	-5,29	27,98
I	8	64	63,29	0,71	0,51
J	10	72	69,19	2,81	7,88
soma	57	565	565	0	152,27

O erro padrão da estimativa

$$Se = \sqrt{\frac{\Sigma(y - \hat{y})^2}{n - 2}}$$

$$Se = \sqrt{\frac{152,27}{8}} = 4,36$$

O erro padrão da estimativa

$$Se = \sqrt{\frac{\Sigma y^2 - \hat{\beta}_0 \Sigma y - \hat{\beta}_1 \Sigma xy}{n - 2}}$$

$$Se = \sqrt{\frac{32581 - 39,6747 * 565 - 2,9518 * 3392}{8}} = 4,36$$

Intervalos de confiança para previsão

- ▶ Dado uma equação de regressão linear específica e x_0 , um valor específico de x , um intervalo de confiança para a previsão de y será:

$$IC(1 - \alpha)100\% = \hat{y} \pm t_{\frac{\alpha}{2}; n-2} \cdot se. \sqrt{1 + \frac{1}{n} + \frac{n(x_0 - \bar{x})^2}{Sxx}}$$

- ▶ Dado uma equação de regressão linear específica e x_0 , um valor específico de x , um intervalo de confiança para a previsão de μ_y será:

$$IC(1 - \alpha)100\% = \hat{y} \pm t_{\frac{\alpha}{2}; n-2} \cdot se. \sqrt{\frac{1}{n} + \frac{n(x_0 - \bar{x})^2}{Sxx}}$$

Intervalos de confiança para previsão

- Assumindo que o modelo de regressão ajustado é adequado, qual o intervalo de 95% para previsão da quantidade de clientes para um funcionário com 8 anos de empresa?

$$IC\ 95\% = 63,29 \pm 2,3060 * 4,37 * \sqrt{1 + \frac{1}{10} + \frac{10(8 - 5,7)^2}{581}}$$

$$IC\ 95\% = 63,29 \pm 2,3060 * 4,37 * 1,08$$

$$IC\ 95\% = 63,29 \pm 10,88$$

$$IC\ 95\% = [52,41; 74,17]$$

Intervalos de confiança para previsão

- Assumindo que o modelo de regressão ajustado é adequado, qual o intervalo de 95% para previsão da média quantidade de clientes para um grupo de funcionários com 8 anos de empresa?

$$IC\ 95\% = 63,29 \pm 2,3060 * 4,37 * \sqrt{\frac{1}{10} + \frac{10(8 - 5,7)^2}{581}}$$

$$IC\ 95\% = 63,29 \pm 2,3060 * 4,37 * 0,42$$

$$IC\ 95\% = 63,29 \pm 4,23$$

$$IC\ 95\% = [59,06; 67,52]$$




TABELA - Distribuição t de Student (Unicaudal e Bicaudal)

φ = graus de liberdade

α φ	25%	10%	5%	2,5%	1%	0,5%
1	1,0000	3,0777	6,3138	12,7062	31,8207	63,6574
2	0,8165	1,8856	2,9200	4,3027	6,9646	9,9248
3	0,7649	1,6377	2,3534	3,1824	4,5407	5,8409
4	0,7407	1,5332	2,1318	2,7764	3,7469	4,6041
5	0,7267	1,4759	2,0150	2,5706	3,3649	4,0322
6	0,7176	1,4398	1,9432	2,4469	3,1427	3,7074
7	0,7111	1,4149	1,8946	2,3646	2,9980	3,4995
8	0,7064	1,3968	1,8595	2,3060	2,8965	3,3554
9	0,7027	1,3830	1,8331	2,2622	2,8214	3,2498
10	0,6998	1,3722	1,8125	2,2281	2,7638	3,1693
11	0,6974	1,3634	1,7959	2,2010	2,7181	3,1058
12	0,6955	1,3562	1,7823	2,1788	2,6810	3,0545
13	0,6938	1,3502	1,7709	2,1604	2,6503	3,0123
14	0,6924	1,3450	1,7613	2,1448	2,6245	2,9768
15	0,6912	1,3406	1,7531	2,1315	2,6025	2,9467
16	0,6901	1,3368	1,7459	2,1199	2,5835	2,9208
17	0,6892	1,3334	1,7396	2,1098	2,5669	2,8982
46	0,6799	1,3002	1,6787	2,0129	2,4102	2,6870
47	0,6797	1,2998	1,6779	2,0117	2,4083	2,6846
48	0,6796	1,2994	1,6772	2,0106	2,4066	2,6822
49	0,6795	1,2991	1,6766	2,0096	2,4049	2,6800
50	0,6794	1,2987	1,6759	2,0086	2,4033	2,6778
51	0,6793	1,2984	1,6753	2,0076	2,4017	2,6757
52	0,6792	1,2980	1,6747	2,0066	2,4002	2,6737
53	0,6791	1,2977	1,6741	2,0057	2,3988	2,6718
54	0,6791	1,2974	1,6736	2,0049	2,3974	2,6700
55	0,6790	1,2971	1,6730	2,0040	2,3961	2,6682
56	0,6789	1,2969	1,6725	2,0032	2,3948	2,6665
57	0,6788	1,2966	1,6720	2,0025	2,3936	2,6649
58	0,6787	1,2963	1,6716	2,0017	2,3924	2,6633
59	0,6787	1,2961	1,6711	2,0010	2,3912	2,6618
60	0,6786	1,2958	1,6706	2,0003	2,3901	2,6603
61	0,6785	1,2956	1,6702	1,9996	2,3890	2,6589
62	0,6785	1,2954	1,6698	1,9990	2,3880	2,6575