

Lista #5

Curso: Ciência da Computação

Disciplina: Inteligência Artificial

Prof^a. Cristiane Neri Nobre

Questão 01

Uma árvore de decisão pode se beneficiar da técnica de poda (pruning) para melhorar a generalização do modelo. Considere o comportamento esperado de uma árvore de decisão que **não utiliza poda** em um conjunto de dados com muito ruído.

Avalie as afirmativas a seguir:

- I. A árvore de decisão tende a se ajustar excessivamente aos dados de treinamento, criando um modelo superajustado (overfitting) que se adapta ao ruído.
- II. A profundidade da árvore pode aumentar desnecessariamente, o que pode levar a um desempenho fraco em novos dados de teste.
- III. A ausência de poda permite que a árvore capture padrões reais nos dados, mesmo em um conjunto com muito ruído, resultando em uma melhor performance de generalização.

Quais das afirmações estão corretas?

A) Apenas I e II

B) Apenas II e III

C) Apenas I e III

D) Todas estão corretas

E) Apenas II está incorreta

Questão 02

Os algoritmos ID3 e C4.5 são utilizados na construção de árvores de decisão, mas apresentam diferenças importantes. Considere as seguintes afirmativas sobre as diferenças entre os dois algoritmos:

- I. O algoritmo ID3 utiliza o ganho de informação como métrica para escolher os atributos, enquanto o C4.5 utiliza o ganho de informação normalizado (razão de ganho) para compensar o viés do ID3 em favor de atributos com muitos valores.
- II. O algoritmo C4.5 pode lidar com atributos contínuos, enquanto o ID3 só trabalha com atributos discretos.
- III. O C4.5 é capaz de lidar com dados ausentes, enquanto o ID3 exige que os dados estejam completos para a construção da árvore.

Quais das afirmações estão corretas?

A) Apenas I e II

B) Apenas II e III

C) Apenas I e III

D) Todas estão corretas

E) Apenas I está incorreta

Questão 03

Os algoritmos ID3, C4.5 e CART são amplamente utilizados na construção de árvores de decisão, cada um com características específicas.

Considere as seguintes afirmativas sobre esses algoritmos:

- I. Tanto o ID3 quanto o C4.5 utilizam o ganho de informação ou o índice de ganho para a escolha dos atributos, enquanto o CART utiliza o critério de Gini ou entropia para essa tarefa.
- II. O algoritmo C4.5 pode lidar com atributos contínuos e discretos, enquanto o ID3 trabalha apenas com atributos discretos. O CART também lida com ambos os tipos de atributos.
- III. Diferentemente do ID3 e do C4.5, o algoritmo CART gera árvores de decisão binárias, ou seja, em cada nó, a divisão é feita sempre em dois ramos.

Quais das afirmações estão corretas?

- A) Apenas I e II
- B) Apenas II e III
- C) Apenas I e III
- D) Todas estão corretas**
- E) Apenas I está incorreta

Questão 04

Sobre a construção de árvores no Random Forest, analise as seguintes afirmações:

- I. Cada árvore na floresta é construída a partir de uma amostra aleatória do conjunto de dados com reposição (bootstrap sampling).
- II. Para cada divisão de nó, o algoritmo considera um subconjunto aleatório de features, o que aumenta a diversidade entre as árvores.
- III. Todas as árvores no Random Forest são treinadas usando exatamente o mesmo subconjunto de features para cada nó.

Quais afirmações estão corretas?

- A) Apenas I e II estão corretas**
- B) Apenas II está correta
- C) Apenas I e III estão corretas
- D) Todas estão corretas

Questão 05

Sobre o uso do F1-score, considere as afirmações:

- I. O F1-score é uma métrica útil quando há um desbalanceamento entre as classes, pois combina precisão e recall em uma única métrica.
- II. O F1-score será alto se tanto a precisão quanto o recall forem altos, e será baixo se uma dessas métricas for baixa, mesmo que a outra seja alta.
- III. O F1-score é preferido em contextos onde os falsos negativos são mais custosos que os falsos positivos.

Quais estão corretas?

- A) Apenas I está correta
- B) Apenas II está correta
- C) Apenas I e II estão corretas**
- D) Apenas II e III estão corretas
- E) Todas estão corretas

Questão 06

Considere a seguinte matriz de confusão para um classificador com 3 classes A, B e C:


	Predito: A	Predito: B	Predito: C
Real: A	50	10	5
Real: B	15	40	10
Real: C	5	10	55

Calcule a **Taxa de Verdadeiro Negativo (TVN)** da classe A.

- A. 0,71
- B. 0,77
- C. 0,85**
- D. 0,80
- E. 0,83

Questão 07

A figura abaixo mostra uma árvore de decisão construída por um algoritmo de aprendizado indutivo a partir de um conjunto de dados em que as instâncias são classificadas em **Câncer recorrente** ou **Câncer não Recorrente**.



Considerando-se as seguintes afirmações:

- I. Quanto maior o valor do gini, mais puro é o nó
- II. A maior cobertura por classe gerada a partir das regras é de aproximadamente 61%
- III. A atributo “tumor-size é o que tem maior entropia nesta base de dados

É **correto** o que se afirma em:

- a) II, apenas.**
- b) III, apenas.
- c) I e II, apenas.
- d) I e III, apenas.
- e) I, II e III.

Questão 08

Em um problema de classificação com classes desbalanceadas, é comum aplicar técnicas de oversampling ou undersampling. Considere as afirmativas a seguir:

- I. O oversampling aumenta a quantidade de instâncias da classe minoritária, o que pode levar ao overfitting, especialmente quando se duplicam instâncias existentes.
- II. O undersampling reduz a quantidade de instâncias da classe majoritária, o que pode levar à perda de informação relevante.
- III. O uso de técnicas de balanceamento como SMOTE (Synthetic Minority Over-sampling Technique) pode ajudar a criar instâncias sintéticas da classe minoritária e melhorar a generalização do modelo.

Quais afirmativas estão corretas?

- a) Apenas I e II
- b) Apenas II e III
- c) Apenas I e III
- d) **Todas estão corretas**
- e) Apenas III está correta

Questão 09

Em relação à aplicação prática das técnicas de oversampling e undersampling no aprendizado supervisionado, analise as afirmativas:

- I. Técnicas de oversampling como SMOTE devem ser aplicadas apenas após o split dos dados em treino e teste para evitar vazamento de dados (data leakage).
- II. O undersampling pode ser útil em conjuntos de dados muito grandes, pois reduz o tempo de treinamento ao diminuir o número de exemplos.
- III. Um modelo treinado em dados balanceados geralmente apresenta melhor recall para a classe minoritária em comparação com um modelo treinado em dados desbalanceados.

Quais afirmativas estão corretas?

- a) Apenas I e II
- b) Apenas II e III
- c) Apenas I e III
- d) **Todas estão corretas**
- e) Apenas I está correta

Questão 10

No pré-processamento de dados para modelos de aprendizado de máquina, a imputação de valores ausentes é uma etapa fundamental. Analise as afirmativas a seguir:

- I. A imputação pela média ou mediana pode distorcer a distribuição original dos dados, especialmente se houver outliers.
- II. A técnica de imputação mais apropriada depende do tipo de variável (numérica, categórica, ordinal) e da natureza do problema
- III. Ignorar os valores ausentes e remover diretamente as linhas com dados faltantes nunca é uma boa prática e deve ser evitado em qualquer circunstância.

Quais afirmativas estão corretas?

- a) **Apenas I e II**
- b) Apenas II e III
- c) Apenas I e III

- d) Todas estão corretas
- e) Apenas II está correta

Questão 11

Considere agora algumas técnicas e boas práticas em imputação de dados ausentes:

- I. Técnicas avançadas como KNN imputation e regressão multivariada consideram a correlação entre variáveis para estimar os valores ausentes.
- II. A imputação deve ser aplicada antes do split dos dados em treino e teste para garantir consistência estatística no processo.
- III. Em pipelines profissionais, a imputação é frequentemente combinada com validação cruzada para evitar o vazamento de dados (data leakage).

Quais afirmativas estão corretas?

- a) Apenas I e II
- b) Apenas II e III
- c) Apenas I e III**
- d) Todas estão corretas
- e) Apenas I está correta

Questão 12

Em relação às técnicas de codificação de variáveis categóricas em aprendizado de máquina, analise as afirmativas:

- I. O Label Encoding pode induzir um modelo a assumir uma ordem inexistente entre categorias, o que pode ser problemático em algoritmos baseados em distância ou regressão.
- II. O One-Hot Encoding pode aumentar significativamente a dimensionalidade do conjunto de dados, especialmente em variáveis com muitos níveis (cardinalidade alta).
- III. O Frequency Encoding substitui cada categoria pela frequência relativa de sua ocorrência, preservando informações de ordem entre as categorias.

Quais afirmativas estão corretas?

- a) Apenas I e II**
- b) Apenas II e III
- c) Apenas I e III
- d) Todas estão corretas
- e) Apenas III está correta

Questão 13

Considere o uso das classes `DecisionTreeClassifier` e `RandomForestClassifier` do módulo `sklearn.ensemble` e `sklearn.tree`. Analise as afirmativas abaixo:

- I. O método `.fit(X, y)` é usado tanto em `DecisionTreeClassifier` quanto em `RandomForestClassifier` para treinar o modelo com os dados de entrada `X` e os rótulos `y`.
- II. Após o treinamento, é possível prever os valores de teste com o método `.predict(X_test)` em ambos os modelos.
- III. A escolha de `criterion='entropy'` ou `criterion='gini'` está disponível apenas para o `DecisionTreeClassifier`.

Quais afirmativas estão corretas?

- a) Apenas I e II**
- b) Apenas II e III
- c) Apenas I e III
- d) Todas estão corretas
- e) Apenas III está correta

Questão 14

Considere a configuração de hiperparâmetros nos algoritmos de árvore de decisão e floresta aleatória (RandomForestClassifier).

Analise:

- I. O hiperparâmetro `max_depth` controla a profundidade máxima de cada árvore tanto na `DecisionTreeClassifier` quanto na `RandomForestClassifier`.
- II. O parâmetro `n_estimators` define o número de árvores utilizadas no `RandomForestClassifier`.
- III. O parâmetro `random_state` garante reprodutibilidade dos resultados em ambos os modelos ao fixar a semente dos geradores aleatórios.

Quais afirmativas estão corretas?

- a) Apenas I e II
- b) Apenas II e III
- c) Apenas I e III
- d) Todas estão corretas**
- e) Apenas I está correta