


Cauã Costa Alves – 855926

Observação: Para todas as listas que envolvem a implementação das funções em Python, solicita-se que:

1. Todas as discussões das questões devem estar contidas na lista. Ou seja, todas as decisões e explicações necessárias precisam estar na lista, que só pode ser entregue em PDF. **Listas em qualquer outro formato serão zeradas.**
2. Os links para os códigos desenvolvidos devem estar inseridos na lista, com as devidas permissão de acesso. **Listas sem permissão de acesso serão zeradas.**

Questão 01

Considerando-se os códigos (Lendo_e_tratando_arquivo_v2.ipynb DecisionTree_Restaurante.ipynb) disponibilizados no CANVAS, pede-se: 1) Gerar a árvore para a base de dados **Restaurante**, alterando a codificação do atributo **cliente** para conter a seguinte codificação:




Questão 02

Baseado nestes códigos acima, encontrar o padrão de pessoas que sobreviveram ao desastre do TITANIC, que matou mais de 1.500 pessoas em 1912. A base de dados do TITANIC está no CANVAS.


1. Visualize a base de dados primeiro, veja como estão os atributos e suas distribuições.
2. Investigue a melhor forma de codificar cada atributo da base de dados.
3. Forneça as regras que mostre o padrão de mortalidade.

R: As principais regras extraídas foram: mulheres sobreviveram em maior proporção que homens; passageiros de 1ª e 2ª classe tiveram maior taxa de sobrevivência que os da 3ª; e crianças pequenas tinham mais chance de sobreviver. Além disso, tarifas mais altas correlacionaram positivamente com sobrevivência.

Base usada “train.csv”:



Acurácia:



Acurácia: 0.770949720670391

Relatório de classificação:				
	precision	recall	f1-score	support
Morreu	0.81	0.79	0.80	105
Sobreviveu	0.71	0.74	0.73	74

Questão 03

Leia o artigo “[A_comparative_study_of_decision_tree_ID3_and_C4.5.pdf](#)” que está no CANVAS e responda:

1) Quais as diferenças entre os algoritmos de árvore ID3 e C4.5?

R: O ID3 foi a base, mas limitado; o C4.5 é a versão melhorada, mais robusta e prática, principalmente porque lida com valores contínuos, faltantes e faz poda, resultando em modelos mais generalizáveis.

2) Como o algoritmo C4.5 lida com os atributos de entrada que são numéricos?

1 - Ordena os valores contínuos em ordem crescente.

2 - Testa potenciais pontos de corte (thresholds) do tipo “ $\leq t$ ” e “ $> t$ ”.


3 - Para cada corte, calcula o *gain ratio* e escolhe o ponto que maximiza a separação.

4 - Isso transforma atributos contínuos em divisões binárias otimizadas durante a construção da árvore

Questão 04

A figura abaixo mostra uma árvore de decisão construída por um algoritmo de aprendizado indutivo a partir de um conjunto de dados em que as instâncias são descritas por quatro atributos: **Tamanho** da Pétala, **largura** da Pétala, **Tamanho** da Sépala e **Largura** da Sépala.

Dado um objeto de classe desconhecida, essa árvore classifica o objeto nas classes: **Iris_Setosa**, **Iris_Virgínica** e **Iris_Versicolor**. Esta árvore foi gerada com os hiperparâmetros (DecisionTreeClassifier(criterion='gini', max_depth=3)), usando a linguagem Python.



Com base nestas informações, qual as saídas da árvore para os seguintes **registros de teste**, respectivamente?

Registros de teste	Tamanho da Pétala	Largura da Pétala	Tamanho da Sépala	Largura da Sépala
Instância 1	3.46	0.87	2.45	1.78
Instância 2	1.67	1.89	0.78	1.32
Instância 3	2.56	2.34	2.45	1.78
Instância 4	6.67	2.34	2.45	1.78

- a) Iris_Virgínica, Íris_Setosa, Iris_Versicolor, Iris_Virgínica
 - b) Iris_Setosa, Íris_Setosa, Iris_Virgínica, Iris_Versicolor
 - c) Iris_Versicolor, Íris_Setosa, Iris_Versicolor, Iris_Virgínica
 - d) Íris_Setosa, Iris_Virgínica, Iris_Virgínica, Iris_Versicolor
 - e) Iris_Versicolor, Íris_Setosa, Iris_Versicolor, Íris_Setosa
- R:** c) Iris_Versicolor, Íris_Setosa, Iris_Versicolor, Iris_Virgínica

Questão 05

Considerando a árvore da questão anterior, e as seguintes afirmações:

- I. Esta árvore possui 5 regras de classificação
- II. Das regras geradas, há apenas uma com cobertura por classe de 100%
- III. A menor cobertura por classe é de 6.8% e corresponde à classe Iris_Virgínica

É **correto** o que se afirma em:

- a) I, apenas.
- b) III, apenas.
- c) I e II, apenas.
- d) I e III, apenas.
- e) I, II e III.

R: C) I e II, apenas.

Questão 06

Considere a seguinte matriz de confusão obtida por meio do classificador, **Árvore de decisão**, para um problema de quatro classes:

		Foi classificado como			
		A	B	C	D
Era da classe	A	10	4	2	1
	B	1	15	2	0
	C	2	3	20	5
	D	4	1	2	50

Quais os valores para as métricas abaixo para cada uma das classes A, B, C e D?

	Precisão	Recall	F1Score	TVP	TFN	TFP	TVN
A	10/17	10/17	0,5882	10/17	7/17	7/105	98/105
B	15/23	15/18	0,7317	15/18	3/18	8/106	98/106
C	20/26	20/30	0,7143	20/30	10/30	6/92	86/92
D	50/56	50/57	0,885	50/57	7/57	6/65	59/65