


REDES NEURAIS PROFUNDAS

REDES NEURAIS CONVOLUCIONAIS

Cristiane Neri Nobre

Introdução



Fonte: <https://www.deeplearningbook.com.br/uma-breve-historia-das-redes-neurais-artificiais/>

Introdução

- As origens das redes neurais convolucionais remontam aos anos 70.
- Mas o artigo seminal que estabeleceu o tema moderno das redes convolucionais foi um artigo de 1998, “[Gradient-based learning applied to document recognition](#)”, de Yann LeCun, Léon Bottou, Yoshua Bengio e Patrick Haffner

PROC. OF THE IEEE, NOVEMBER 1998

1

Gradient-Based Learning Applied to Document Recognition

Yann LeCun, Léon Bottou, Yoshua Bengio, and Patrick Haffner

Introdução

- Teoria “antiga”, mas ganhou protagonismo a **partir de 2012**
- **Alex Krizhevsky** reduziu erro de 26% para 15% na competição ImageNet (“olimpíada” da Visão Computacional)
- Pouco depois de ter vencido o desafio ImageNet 2012, por meio do AlexNet , ele e seus colegas venderam sua startup DNN Research Inc. para o Google



Fonte: https://en.wikipedia.org/wiki/Alex_Krizhevsky

Introdução

- Despertou interesse de empresas como Google (busca de imagens), Amazon (recomendação de produtos), Instagram (sistema de busca), Facebook (marcação de usuários em fotos), etc.
- **Meados dos anos 2000:** o termo “aprendizagem profunda” começa a ganhar popularidade após um artigo de **Geoffrey Hinton e Ruslan Salakhutdinov** mostrar como uma rede neural de várias camadas poderia ser pré-treinada uma camada por vez.

Deep Boltzmann Machines

Ruslan Salakhutdinov
Department of Computer Science
University of Toronto
rsalakhu@cs.toronto.edu

Geoffrey Hinton
Department of Computer Science
University of Toronto
hinton@cs.toronto.edu

Veja entrevista com Ruslan
<https://www.deeplearning.ai/hodl-ruslan-salakhutdinov/>

Introdução

- **2017:** adoção em massa do **Deep Learning** em diversas aplicações corporativas e mobile, além do avanço em pesquisas. Todos os eventos de tecnologia ligados a Data Science, IA e Big Data, apontam Deep Learning como a principal tecnologia para criação de sistemas inteligentes.

Leia mais em:

<https://www.deeplearningbook.com.br/uma-breve-historia-das-redes-neurais-artificiais/>


Redes neurais densas

O aprendizado profundo, embora pareça chamativo, é realmente apenas um termo para descrever certos tipos de redes neurais e algoritmos relacionados que consomem dados de entrada geralmente muito brutos.


Eles **processam** esses dados por meio de muitas camadas de transformações não lineares dos dados de entrada para calcular uma saída de destino

Tecnicamente, **uma rede neural artificial (ANN) que possui muitas camadas é uma Deep Neural Network (DNN)**

Simple Neural Network



Deep Learning Neural Network





● Input Layer



● Hidden Layer

● Output Layer

Redes Neurais densas



Redes Neurais densas




Redes Neurais densas

- Mas, após reflexão, é estranho usar redes com camadas totalmente conectadas para classificar imagens.
- A razão é que tal arquitetura de rede não leva em conta a estrutura espacial das imagens. Por exemplo, ela trata os pixels de entrada que estão distantes e próximos exatamente no mesmo nível

Inspiração biológica para redes neurais convolucionais

- O cérebro reconhece objetos partindo de primitivas básicas, p.ex. patas e rabo de um cachorro, e vai iterativamente construindo conceitos mais abstratos.
 - ✓ Orientação seletiva – campo receptivo local

- Assim, temos:



Redes neurais convolucionais

Uma Rede Neural Convolucional (ConvNet / Convolutional Neural Network / CNN) é um algoritmo de **Aprendizado Profundo** que pode captar uma imagem de entrada, atribuir importância (pesos e vieses que podem ser aprendidos) a vários aspectos / objetos da imagem e ser capaz de diferenciar um do outro.

Assim, uma **rede neural convolucional (CNN/ConvNet)** é uma classe de redes neurais profundas , mais comumente aplicada para analisar imagens visuais.

Redes neurais convolucionais (CNN)

As CNN funcionam em 4 etapas:

- Etapa 1: Operador de convolução
- Etapa 2: *Pooling*
- Etapa 3: *Flattening*
- Etapa 4: Rede neural densa

Etapa 1 - Operador de convolução

- Convolução é o processo de adicionar cada elemento da imagem para seus vizinhos, ponderado por um *kernel*
- A imagem é uma matriz e o Kernel é outra matriz

Etapa 1 - Operador de convolução

- **Explicações sobre os Kernels**

[https://en.wikipedia.org/wiki/Kernel_\(image_processing\)](https://en.wikipedia.org/wiki/Kernel_(image_processing))

- **Exemplo online**

<https://setosa.io/ev/image-kernels/>

Etapa 1 - Operador de convolução

0	0	0	0	0	0	0
0	1	0	0	0	1	0
0	0	0	0	0	0	0
0	0	0	1	0	1	1
0	1	0	1	1	0	0
0	1	0	1	1	0	1
0	1	0	0	0	1	1

Imagem 7x7

x

1	0	0
1	0	1
0	1	1

=

Detector de características
Feature detector

0				

$$0*1 + 0*0 + 0*0 + 0*1 + 1*0 + 0*1 + 0*0 + 0*1 + 0*1 = 0$$

Etapa 1 - Operador de convolução

0	0	0	0	0	0	0
0	1	0	0	0	1	0
0	0	0	0	0	0	0
0	0	0	1	0	1	1
0	1	0	1	1	0	0
0	1	0	1	1	0	1
0	1	0	0	0	1	1

Imagem 7x7

x

1	0	0
1	0	1
0	1	1

=

Detector de características
Feature detector

0	1			

$$0*1 + 0*0 + 0*0 + 1*1 + 0*0 + 0*1 + 0*0 + 0*1 + 0*1 = 1$$

Etapa 1 - Operador de convolução

0	0	0	0	0	0	0
0	1	0	0	0	1	0
0	0	0	0	0	0	0
0	0	0	1	0	1	1
0	1	0	1	1	0	0
0	1	0	1	1	0	1
0	1	0	0	0	1	1

Imagem 7x7

X

1	0	0
1	0	1
0	1	1

=

Detector de características
Feature detector

0	1	0		

$$0*1 + 0*0 + 0*0 + 0*1 + 0*0 + 0*1 + 0*0 + 0*1 + 0*1 = 0$$

Etapa 1 - Operador de convolução

0	0	0	0	0	0	0
0	1	0	0	0	1	0
0	0	0	0	0	0	0
0	0	0	1	0	1	1
0	1	0	1	1	0	0
0	1	0	1	1	0	1
0	1	0	0	0	1	1

Imagem 7x7

x

1	0	0
1	0	1
0	1	1

Detector de características
Feature detector

=

0	1	0	1	0
0	2	1	1	2
1	2	2	3	1
1	3	3	3	2
1	3	1	3	5

Mapa de características
Feature map

$$1*1 + 0*0 + 0*0 + 1*1 + 0*0 + 1*1 + 0*0 + 1*1 + 1*1 = 5$$

Etapa 1 - Operador de convolução

- Com o mapa de características (*filter map*), a imagem fica menor para facilitar o processamento
- Alguma informação sobre a imagem pode ser perdida, porém o propósito é detectar as partes principais (quanto maior os valores melhor)
- O mapa de características preserva as características principais da imagem (olho, boca, etc)

Etapa 1 - Operador de convolução (RELU)

0	0	0	0	0	0	0
0	1	0	0	0	1	0
0	0	0	0	0	0	0
0	0	0	1	0	1	1
0	1	0	1	1	0	0
0	1	0	1	1	0	1
0	1	0	0	0	1	1

Imagem 7x7

X


1	0	0
1	0	1
0	1	1

=

Detector de características
Feature detector

0	1	0	1	0
0	2	1	1	2
1	2	2	3	1
1	3	3	3	2
1	3	1	3	5

Mapa de características
Feature map



Etapa 1 - Camada de convolução

0	0	0	0	0	0	0
0	1	0	0	0	1	0
0	0	0	0	0	0	0
0	0	0	1	0	1	1
0	1	0	1	1	0	0
0	1	0	1	1	0	1
0	1	0	0	0	1	1

Imagem



Qual o melhor
detector
de características?

0	1	0	1	0			
0	1	0	1	0			
0	1	0	1	0			
0	0	1	0	1	0		
1	0	0	1	0	1	0	
1	1	0	0	1	0	1	0
1	1	1	0	2	1	1	2
1	1	1	1	2	2	3	1
1	1	3	3	3	3	2	
1	3	1	3	5			

Mapas de características
Feature map

Blurring (Reduces Noise)



*

0.1	0.1	0.1
0.1	0.1	0.1
0.1	0.1	0.1

=



Edge detect:



*


-1	-1	-1
-1	8	-1
-1	-1	-1

=




Etapa 2 - Pooling

- Seleciona as características mais relevantes da imagem (reduz overfitting e ruídos)
- Pode-se usar o máximo, o mínimo a média dos valores, dentre outros




Etapa 2 - Pooling

- Seleciona as características mais relevantes da imagem (reduz overfitting e ruídos)
- Pode-se usar o máximo, o mínimo a média dos valores




Etapa 2 - Pooling

- Seleciona as características mais relevantes da imagem (reduz overfitting e ruídos)
- Pode-se usar o máximo, o mínimo a média dos valores




Etapa 2 - Pooling


- Seleciona as características mais relevantes da imagem (reduz overfitting e ruídos)
- Pode-se usar o máximo, o mínimo a média dos valores




Etapa 2 - Pooling




Max Pooling



Stochastic Pooling




S3Pool



Extraído de

https://openaccess.thecvf.com/content_cvpr_2017/papers/Zhai_S3Pool_Pooling_With_CVPR_2017_paper.pdf

Etapa 2 - Pooling



Etapa 2 - Pooling

0	0	0	0	0	0	0
0	1	0	0	0	1	0
0	0	0	0	0	0	0
0	0	0	1	0	1	1
0	1	0	1	1	0	0
0	1	0	1	1	0	1
0	1	0	0	0	1	1

Imagem



0	1	0	1	0			
0	1	0	1	0			
0	1	0	1	0			
0	0	1	0	1	0		
1	0	0	1	0	1	0	
1	1	0	0	1	0	1	0
1	1	1	0	2	1	1	2
1	1	1	1	2	2	3	1
1	1	1	3	3	3	2	
1	3	1	3	5			



Mapas de características (**com aplicação da função de ativação RELU**) (Feature map)

2	1	2
3	3	2
3	3	5

Max Pooling




Etapa 3 - Flattening



Rede neural densa

Resumo da CNN



Fonte: <https://www.deeplearningbook.com.br/as-10-principais-arquiteturas-de-redes-neurais/>

Resumo da CNN

Veja uma simulação em:

https://adamharley.com/nn_vis/cnn/2d.html

Alguns tipos de CNN

Arquitetura	Ano	Características	Utilizado em	Artigo
LeNet	1998	Primeiras aplicações bem-sucedidas de CNNs, 5 camadas (alternando entre convolucional e pooling), Funções de ativação tanh/sigmóide usadas	Reconhecer caracteres manuscritos e impressos à máquina	http://yann.lecun.com/exdb/publis/pdf/lecun-01a.pdf
AlexNet	2012	Mais profundo e mais amplo que LeNet, função de ativação ReLU usada, camadas de abandono implementada	Tarefas de reconhecimento de imagem em grande escala	https://proceedings.neurips.cc/paper_files/paper/2012/file/c399862d3b9d6b76c8436e924a68c45b-Paper.pdf
ZFNet	2013	Arquitetura semelhante à AlexNet, mas com tamanhos e números de filtros diferentes, Técnicas de visualização para entender a rede	Classificação ImageNet	
VGGNet	2014	Redes mais profundas com filtros menores (3×3), Todas as camadas convolucionais têm a mesma profundidade, Múltiplas configurações (VGG16, VGG19)	Reconhecimento de imagem em grande escala	https://arxiv.org/pdf/1409.1556
ResNet	2015	Introduziu “pular conexões” ou “atalhos” para permitir o treinamento de redes mais profundas. Múltiplas configurações (ResNet-50, ResNet-101, ResNet-152)	Reconhecimento de imagem em grande escala, conquistou o 1º lugar no ILSVRC 2015	https://arxiv.org/abs/1512.03385
GoogleLeNet	2014	Introduzido o módulo Inception, que permite computação mais eficiente e redes mais profundas, múltiplas versões (Inception v1, v2, v3, v4)	Reconhecimento de imagem em grande escala, conquistou o 1º lugar no ILSVRC 2014	https://arxiv.org/pdf/1409.4842
MobileNets	2017	Projetado para aplicações de visão móveis e incorporadas, usa convoluções separáveis em profundidade para reduzir o tamanho e a complexidade do modelo	Aplicativos de visão móveis e incorporados, detecção de objetos em tempo real	

<https://vitalflux.com/different-types-of-cnn-architectures-explained-examples/>

<https://www.analytixlabs.co.in/blog/convolutional-neural-network/>

Alguns tipos de CNN

Leia o artigo:

Application of Convolutional Neural Networks in Weed Detection and Identification: A Systematic Review

Disponível em: <https://www.mdpi.com/2077-0472/14/4/568>

Referências

Slides baseados no material de Jones

<https://www.youtube.com/watch?v=7dsDHb6qKYI>

<https://www.deeplearningbook.com.br/uma-breve-historia-das-redes-neurais-artificiais/>

<https://www.ibm.com/cloud/blog/ai-vs-machine-learning-vs-deep-learning-vs-neural-networks>

https://www.youtube.com/watch?v=n4rmrZg1_58

<https://www.youtube.com/watch?v=-anhRVmYOr8>

Veja um exemplo em Python

https://www.youtube.com/watch?v=Jy9-aGMB_TE

Veja exemplo em Python para reconhecer gatos e cachorros

<https://www.deeplearningbook.com.br/reconhecimento-de-imagens-com-redes-neurais-convolucionais-em-python-parte-4/>

Exercícios

1. Teste a CNN para reconhecimento dos personagens Bart e Homer

<https://www.kaggle.com/datasets/williamu32/dataset-bart-or-homer?resource=download>

Altere a estrutura da CNN, alterando número de camadas de convolução, pooling, kernels, etc

2. Experimente a estrutura em imagens do seu interesse (Câncer de mama, próstata, MNIST, COVID, etc)